

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

Đồ án 1

TIỀN XỬ LÝ DỮ LIỆU

Lớp: CQ2023/21

Giảng viên: Th.S Lê Nhật Nam

Nhóm 5: Cao Tiến Thành - 23120088
Đỗ Quốc Thịnh - 23120089
Cao Thanh Bình - 23120216
Nguyễn Văn Chiến - 23120219
Đặng Nguyễn Thái Đạt - 23120227

Thành phố Hồ Chí Minh, 04/2026

Mục lục

Danh mục hình ảnh	3
Danh mục bảng	4
1 Phần 1: Tiền xử lý dữ liệu ảnh số	5
1.1 Mô tả tập dữ liệu	5
1.2 Tóm tắt điều hành	5
1.3 Phân tích thống kê tập dữ liệu	6
1.3.1 Phân phối giá trị pixel theo kênh màu	6
1.3.2 Mất cân bằng lớp (Class Imbalance)	6
1.3.3 Phát hiện ảnh trùng lặp bằng Perceptual Hash (pHash)	7
1.3.4 Độ tương phản và độ sáng	7
1.4 Các kỹ thuật tiền xử lý và Ablation Study	8
1.4.1 Resize và chất lượng ảnh	8
1.4.2 Không gian màu	8
1.4.3 Chuẩn hóa (Normalization)	9
1.4.4 Tăng cường dữ liệu (Data Augmentation)	10
1.4.5 Phân tích PCA và trực quan hóa	11
1.4.6 Phát hiện cạnh và ANOVA	13
1.5 Tổng kết lựa chọn cuối cùng	14
1.6 Hạn chế và hướng cải tiến	14
2 Phần 2: Tiền xử lý dữ liệu dạng bảng	15
2.1 Mô tả tập dữ liệu	15
2.2 Phân tích thống kê khám phá (EDA chuyên sâu)	15
2.2.1 Kiểm tra phân phối từng thuộc tính số	15
2.2.2 Phân tích tương quan đa biến (Pearson và Spearman)	16
2.2.3 Phân tích giá trị thiếu và cơ chế thiếu dữ liệu	17
2.3 Tóm tắt điều hành	17
2.4 Các kỹ thuật tiền xử lý và đánh giá định lượng	19
2.4.1 Xử lý giá trị thiếu	19
2.4.2 Phát hiện và xử lý ngoại lai	20
2.4.3 Chuẩn hóa dữ liệu	21
2.4.4 Mã hóa biến phân loại	21
2.4.5 Lựa chọn và giảm chiều đặc trưng	22
2.4.6 Phát hiện và xử lý mất cân bằng lớp	22
2.5 Kết luận chung	23
3 Phần 3: Tiền xử lý dữ liệu chuỗi thời gian	23
3.1 Mô tả tập dữ liệu	23
3.2 Nhận xét ban đầu	24
3.3 Tóm tắt điều hành	24
3.4 Phân tích khám phá dữ liệu (EDA)	25
3.4.1 Biểu đồ chuỗi thời gian	25
3.4.2 Phân tích Rolling Statistics	25
3.4.3 Phân tích ACF và PACF	25
3.4.4 Phân phối dữ liệu	26

3.4.5	Tổng kết EDA	26
3.5	Các kỹ thuật tiền xử lý	27
3.5.1	Xử lý dữ liệu thiếu	27
3.5.2	Kiểm định tính dừng	28
3.5.3	Biến đổi dữ liệu	28
3.5.4	Phân rã chuỗi thời gian	29
3.5.5	Trích xuất đặc trưng	29
3.6	Ablation Study	30
3.7	Thảo luận	30
3.8	Tổng kết	30
4	Phân công công việc	31
5	Tài liệu tham khảo	32

Danh mục hình ảnh

1	Ma trận tương quan Pearson và Spearman	16
2	Minh họa so sánh các phương pháp điền khuyết	19
3	Biểu đồ ACF của chuỗi giá cổ phiếu VNDA	25
4	Biểu đồ PACF của chuỗi giá cổ phiếu VNDA	26

Danh mục bảng

1	Thống kê phân phối pixel theo kênh màu	6
2	Số lượng và tỷ lệ ảnh theo lớp	6
3	Kết quả phát hiện ảnh trùng lặp	7
4	Mean Intensity và Standard Deviation (Contrast) theo từng lớp	7
5	Kết quả SSIM/PSNR theo kích thước	8
6	Ablation Study - k-NN Accuracy theo kích thước	8
7	Explained Variance (PCA, k=50)	8
8	Ablation Study - Classification Accuracy	9
9	Kết quả KS Test	9
10	Ablation Study - Classification Accuracy	9
11	Kết quả Silhouette Score trước và sau Augmentation	10
12	Ablation Study - Tác động của Augmentation lên Classification	10
13	So sánh theo cường độ Augmentation	10
14	Số components cần thiết theo ngưỡng Variance (32×32)	11
15	Silhouette Score cho các phương pháp	12
16	Ablation Study - k-NN (10,000 samples)	12
17	Ablation Study - Logistic Regression (10,000 samples)	12
18	Edge Density theo phương pháp và cấu hình	13
19	Tổng kết các lựa chọn cuối cùng cho Phần 1	14
21	So sánh các phương pháp điền khuyết trên biến số (dựa trên RMSE trung bình sau 10 lần lặp)	19
22	So sánh các phương pháp phát hiện ngoại lai	20
23	So sánh các phương pháp chuẩn hóa	21
24	So sánh các phương pháp mã hóa (trên biến occupation)	21
25	Hiệu suất (F1-Macro) của các phương pháp chọn đặc trưng tốt nhất	22
26	Đánh giá các chiến lược cân bằng lớp trên tập kiểm tra (test set)	22
27	So sánh các phương pháp xử lý dữ liệu thiếu	27
28	Kết quả kiểm định tính dừng	28
29	Kết quả kiểm định sau sai phân	28
30	Tỷ lệ phương sai của các thành phần sau phân rã	29
31	So sánh hiệu quả của các đặc trưng	30
32	Bảng phân công công việc nhóm	31

1 Phần 1: Tiền xử lý dữ liệu ảnh số

1.1 Mô tả tập dữ liệu

Tập dữ liệu được sử dụng là CIFAR-10 (`data_batch_1`), một phần của tập dữ liệu CIFAR-10 gốc do Alex Krizhevsky tạo ra. Đây là tập dữ liệu chuẩn trong lĩnh vực nhận dạng ảnh và học sâu.

- **Số lượng ảnh:** 10.000 ảnh (từ `data_batch_1`)
- **Kích thước ảnh:** 32×32 pixels, 3 kênh màu (RGB)
- **Số lớp:** 10 lớp đối tượng
- **Các lớp:** airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck

Lý do chọn: CIFAR-10 là tập dữ liệu chuẩn, dễ tiếp cận, có độ khó vừa phải để đánh giá các kỹ thuật tiền xử lý. Dataset được thiết kế cân bằng từ đầu, phù hợp để đánh giá tác động của các kỹ thuật tiền xử lý lên hiệu suất phân loại.

1.2 Tóm tắt điều hành

Phần này tập trung phân tích và đánh giá các kỹ thuật tiền xử lý dữ liệu ảnh số trên tập dữ liệu CIFAR-10. Sau khi thực hiện các phương pháp EDA và tiền xử lý, chúng tôi rút ra các kết luận chính sau:

1. **Dataset CIFAR-10 (`data_batch_1`, 10.000 ảnh) đã ở trạng thái cân bằng** với Imbalance Ratio = 1.10 và p-value kiểm định Chi-square = 0.55 > 0.05. Do đó, không cần áp dụng các kỹ thuật xử lý mất cân bằng lớp.
2. **Phân phối giá trị pixel không tuân theo phân phối chuẩn** (KS test p-value ≈ 0 cho tất cả các kênh R, G, B). Điều này ảnh hưởng đến việc lựa chọn phương pháp chuẩn hóa.
3. **Resizing từ 32×32 xuống 28×28** đạt SSIM = 0.9846 đồng thời cải thiện accuracy từ 0.2895 lên 0.3010 (+1.15%) nhờ hiệu ứng regularization.
4. **Không gian màu LAB cho kết quả phân loại tốt nhất** với k-NN tăng từ 0.2895 lên 0.3020 (+1.25%) và Logistic Regression đạt 0.3480 (cao nhất trong các không gian màu được thử nghiệm).
5. **Min-Max [0,1] là phương pháp chuẩn hóa tốt nhất cho Logistic Regression**, cải thiện accuracy từ 0.274 lên 0.3365 (+6.25%).
6. **Chỉ phát hiện 1 cặp ảnh trùng lặp chính xác** trong tập dữ liệu, tỷ lệ rất thấp (0.01%).

Khuyến nghị: Sử dụng kết hợp Resize 28×28 + LAB Color Space + Min-Max [0,1] cho các bước tiền xử lý ảnh tiếp theo.

1.3 Phân tích thống kê tập dữ liệu

1.3.1 Phân phối giá trị pixel theo kênh màu

Bảng 1: Thống kê phân phối pixel theo kênh màu

Kênh	Mean	Std	Skewness	Kurtosis
Red	125.83	63.14	0.1202 (lệch phải)	-0.7701 (phẳng)
Green	123.26	62.37	0.1641 (lệch phải)	-0.7180 (phẳng)
Blue	114.03	66.97	0.3869 (lệch phải)	-0.8087 (phẳng)
Grayscale	122.98	61.26	-	-

Kết quả kiểm định Kolmogorov-Smirnov: p-value ≈ 0 cho tất cả các kênh, kết luận phân phối **không phải** phân phối chuẩn.

Phân tích:

- Tất cả kênh có skewness dương (lệch phải) cho thấy ảnh có xu hướng hơi tối (under-exposed)
- Blue channel có mean thấp nhất (114.03) cho thấy xu hướng xanh đậm trong dataset
- Kurtosis âm cho thấy phân phối phẳng hơn phân phối chuẩn (platykurtic)
- Phân phối không chuẩn $\rightarrow$ nên cân nhắc Robust Scaling hoặc Quantile Transform thay vì Z-score

1.3.2 Mất cân bằng lớp (Class Imbalance)

Bảng 2: Số lượng và tỷ lệ ảnh theo lớp

Lớp	Số lượng	Tỷ lệ (%)
airplane	1005	10.05%
automobile	974	9.74%
bird	1032	10.32%
cat	1016	10.16%
deer	999	9.99%
dog	937	9.37%
frog	1030	10.30%
horse	1001	10.01%
ship	1025	10.25%
truck	981	9.81%

Thống kê tổng:

- **Imbalance Ratio (max/min):** 1.1014
- **Kiểm định Chi-square:** $\chi^2 = 7.84$, p-value = 0.5506
- **Gini Impurity:** 0.8999
- **Entropy:** 3.3214 nats

Kết luận: Dataset **CÂN BẰNG**. Không cần xử lý class imbalance.

1.3.3 Phát hiện ảnh trùng lặp bằng Perceptual Hash (pHash)

Bảng 3: Kết quả phát hiện ảnh trùng lặp

Tổng số ảnh	10,000
Số ảnh trùng lặp chính xác	1
Tỷ lệ trùng lặp	0.01%
Số cặp near-duplicate (Hamming < 22)	1,326

Hamming Distance Statistics:

- Min: 13, Max: 50
- Mean: 31.40, Std: 4.27

Ngưỡng quyết định: $T=22$ (theo pHash.org). Chỉ tìm thấy 1 cặp trùng lặp chính xác, không đáng kể.

1.3.4 Độ tương phản và độ sáng

Bảng 4: Mean Intensity và Standard Deviation (Contrast) theo từng lớp

Lớp	Mean Intensity	Std (Contrast)
airplane	143.37	65.27
automobile	116.88	69.22
bird	119.54	60.07
cat	116.17	65.09
deer	111.86	55.01
dog	117.25	64.11
frog	105.99	58.38
horse	119.41	63.97
ship	133.81	63.34
truck	126.01	70.11

Thống kê tổng:

- Mean Intensity trung bình: 121.03
- Standard Deviation trung bình: 63.46

Kết quả kiểm định ANOVA:

- F-statistic: 128.78
- p-value: 2.10×10^{-230}
- Kết luận: Có sự khác biệt có ý nghĩa thống kê về độ sáng giữa các lớp ($p < 0.05$)

Phân tích:

- Lớp *airplane* có mean intensity cao nhất (143.37, ảnh sáng nhất)

- Lớp *frog* có mean intensity thấp nhất (105.99, ảnh tối nhất)
- ANOVA p-value ≈ 0 cho thấy sự khác biệt có ý nghĩa thống kê giữa các lớp
- *ship* và *truck* có std cao nhất (contrast cao), trong khi *deer* có std thấp nhất

1.4 Các kỹ thuật tiền xử lý và Ablation Study

1.4.1 Resize và chất lượng ảnh

Bảng 5: Kết quả SSIM/PSNR theo kích thước

Kích thước	SSIM	PSNR (dB)	Đánh giá
16×16	0.9521	25.06	Mất nhiều thông tin
24×24	0.9794	28.58	Trung bình
28×28	0.9846	29.82	Chấp nhận được

Bảng 6: Ablation Study - k-NN Accuracy theo kích thước

Kích thước	k-NN Accuracy	Delta
16×16	0.3060	+0.0165
24×24	0.2950	+0.0055
28×28	0.3010	+0.0115
32×32 (baseline)	0.2895	+0.0000

Kết luận:

- Chọn 28×28 vì SSIM cao nhất (0.9846) và accuracy improve (+1.15%)
- Downscaling hoạt động như regularization, giảm noise
- 16×16 tốt hơn cho k-NN nhưng mất quá nhiều chi tiết

Thảo luận: Quyết định chọn 28×28 dựa trên sự cân bằng giữa chất lượng ảnh và accuracy. Mặc dù 16×16 đạt accuracy cao hơn (+1.65% so với baseline), kích thước này mất quá nhiều chi tiết và không phù hợp với các mô hình deep learning phổ biến. Ngược lại, 28×28 vẫn giữ được 98.46% cấu trúc ảnh (SSIM) trong khi vẫn cải thiện đáng kể accuracy.

Hạn chế: Chỉ đánh giá với k-NN, chưa thử nghiệm với CNN.

Hướng cải tiến: Thử nghiệm với ResNet, VGG để đánh giá tác động của resize lên deep learning.

1.4.2 Không gian màu

Bảng 7: Explained Variance (PCA, k=50)

Không gian màu	Explained Variance	Số kênh
Grayscale	0.8665	1
RGB	0.8450	3
LAB	0.8390	3
HSV	0.7357	3

Bảng 8: Ablation Study - Classification Accuracy

Không gian	k-NN	Delta (k-NN)	LR Accuracy
LAB	0.3020	+0.0125	0.3480
RGB (baseline)	0.2895	+0.0000	0.3365
HSV	0.2455	-0.0440	0.2730
Grayscale	0.2400	-0.0495	0.2460

Kết luận:

- LAB đạt accuracy cao nhất với cả k-NN (+1.25%) và LR (0.3480)
- Grayscale có EV cao nhất nhưng accuracy thấp nhất (mất thông tin màu)
- LAB được khuyến nghị vì perceptually uniform

Thảo luận: Không gian màu LAB (Lightness, a, b) cho kết quả tốt nhất nhờ tính chất "perceptually uniform", các thay đổi trong LAB tương ứng với cảm nhận thị giác của con người. Điều này đặc biệt quan trọng với CIFAR-10 vì các lớp như "dog" và "cat" có sự khác biệt chủ yếu về màu sắc. RGB có nhược điểm là ba kênh tương quan cao, khó phân biệt. HSV có hue bị ràng buộc modulo 360° , gây khó khăn cho classifier.

Hạn chế: LAB conversion yêu cầu OpenCV, không tương thích với tất cả frameworks.

Hướng cải tiến: Thử YCbCr (YCbCr được sử dụng trong JPEG) so sánh với LAB.

1.4.3 Chuẩn hóa (Normalization)

Bảng 9: Kết quả KS Test

Phương pháp	Phân phối mục tiêu	D-statistic	p-value
Original [0,255]	Original	0.000	1.00
Min-Max [0,1]	Uniform(0,1)	0.094	0.00
Min-Max [-1,1]	Uniform(-1,1)	0.094	0.00
Z-score	Normal(0,1)	0.041	0.00
Z-score per-channel	Normal(0,1)	0.038	0.00

Bảng 10: Ablation Study - Classification Accuracy

Phương pháp	k-NN Accuracy	LR Accuracy
Original [0,255]	0.2895	0.2740
Min-Max [0,1]	0.2895	0.3365
Min-Max [-1,1]	0.2895	0.2950
Z-score global	0.2895	0.2670
Z-score per-channel	0.2905	0.2675

Kết luận:

- k-NN: gần như không thay đổi theo phương pháp chuẩn hóa
- Min-Max [0,1] tốt nhất cho Logistic Regression (+6.25%)

- Chọn Min-Max $[0,1]$ vì phổ biến và tốt cho most models

Thảo luận: Min-Max $[0,1]$ được chọn vì đơn giản, phổ biến, và tương thích với hầu hết các frameworks. Tuy nhiên, kết quả cho thấy k-NN gần như không thay đổi theo phương pháp chuẩn hóa. Điều này là do k-NN sử dụng khoảng cách Euclidean, vốn không nhạy cảm với scale của dữ liệu. Ngược lại, Logistic Regression rất nhạy cảm với scale: Min-Max $[0,1]$ tăng accuracy từ 0.274 lên 0.3365 (+6.25%) trong khi Z-score giảm xuống 0.267.

Hạn chế: Dataset pixel không tuân theo phân phối chuẩn, nên Z-score có thể không hiệu quả bằng Quantile Transform.

Hướng cải tiến: Thử Quantile Transform (uniform và normal output) cho phân phối không chuẩn.

1.4.4 Tăng cường dữ liệu (Data Augmentation)

Pipeline augmentation gồm 6 phép biến đổi:

1. **Random horizontal flip:** Lật ngang ảnh
2. **Random vertical flip:** Lật dọc ảnh
3. **Random rotation:** Xoay ngẫu nhiên $\pm 15^\circ, \pm 30^\circ, \pm 45^\circ$
4. **Random crop:** Cắt ngẫu nhiên với padding
5. **Gaussian noise:** Thêm nhiễu Gaussian với $\sigma = 10, 25, 50$
6. **Brightness/Contrast:** Điều chỉnh độ sáng và tương phản

Bảng 11: Kết quả Silhouette Score trước và sau Augmentation

Dữ liệu	Silhouette Score	Thay đổi
Gốc (không augment)	-0.0529	-
Augmented	-0.0636	-0.0107

Bảng 12: Ablation Study - Tác động của Augmentation lên Classification

Mô hình	Baseline Accuracy	Augmentation	Delta	Nhận xét
k-NN	0.2895	0.2895	+0.0000	Không thay đổi
Logistic Regression	0.3365	0.3225	-0.0140	Giảm

Bảng 13: So sánh theo cường độ Augmentation

Cường độ	k-NN Accuracy	LR Accuracy
Low	0.2895	0.3225
Medium	0.2895	0.3145
High	0.2895	0.2975

t-SNE Visualization: Sau khi augment, các lớp vẫn phân tách rõ ràng trong không gian t-SNE, cho thấy augmentation không làm mất đi thông tin phân lớp cơ bản.

Phân tích:

- Silhouette score âm cho thấy CIFAR-10 có sự overlap giữa các lớp
- Augmentation làm giảm silhouette score (-0.0107), có thể do tạo thêm biến thể
- k-NN không được cải thiện bởi augmentation. Đây là kết quả dự đoán vì k-NN không yêu cầu feature transformation
- Logistic Regression giảm accuracy với augmentation (-1.4%) do boundary trở nên phức tạp hơn
- Augmentation không hiệu quả với simple classifiers trên CIFAR-10 pixel space

Thảo luận: Kết quả cho thấy augmentation không cải thiện simple classifiers (k-NN, LR) trên CIFAR-10. Điều này là do:

- CIFAR-10 đã được thiết kế cân bằng, không cần augmentation để cân bằng lớp
- k-NN và LR không có weight training nên không benefits từ regularization effect của augmentation
- Augmentation trên pixel space tạo thêm noise, làm decision boundary phức tạp hơn
- Deep Learning (CNN) sẽ benefits hơn từ augmentation do có parameter training

Hạn chế: Chỉ test với k-NN và LR, chưa test với CNN.

Hướng cải tiến: Thử với CNN (ResNet, VGG), sử dụng CutMix, MixUp, AutoAugment.

1.4.5 Phân tích PCA và trực quan hóa

Với 3,072 features ($32 \times 32 \times 3$), PCA được áp dụng để giảm chiều và trực quan hóa dữ liệu.

Bảng 14: Số components cần thiết theo ngưỡng Variance (32×32)

Ngưỡng Variance	Số Components	Tỉ lệ giảm chiều
90%	96	96.9%
95%	209	93.2%
99%	625	79.7%

Phân tích Variance:

- Với 3,072 features, cần 96 components để giữ 90% variance
- 95% variance yêu cầu 209 components (gấp đôi 90%)
- 99% variance yêu cầu 625 components (gấp 6.5 lần 90%)
- "Elbow" xuất hiện ở khoảng 20-30 components

Bảng 15: Silhouette Score cho các phương pháp

Phương pháp	Silhouette Score	Đánh giá
Dữ liệu gốc (normalized)	-0.0529	Chồng lấn nhiều
PCA 2D	-0.1178	Chồng lấn nhiều
t-SNE	-0.1363	Chồng lấn nhiều

Phân tích Silhouette Score:

- Tất cả giá trị âm, cho thấy các lớp chồng lấn nghiêm trọng
- Dữ liệu gốc có silhouette tốt nhất (-0.0529) vì giữ nguyên thông tin
- PCA và t-SNE làm giảm silhouette vì mất thông tin và không bảo toàn cấu trúc lớp
- Điều này phù hợp với CIFAR-10: các lớp như cat/dog, automobile/truck rất khó phân tách

Bảng 16: Ablation Study - k-NN (10,000 samples)

Số Components	k-NN Accuracy	Delta so với Baseline
Baseline (32×32)	0.2895	-
10	0.3000	+0.0105
25	0.3390	+0.0495
50	0.3360	+0.0465
75	0.3245	+0.0350
100	0.3125	+0.0230
96 (90%)	0.3165	+0.0270
209 (95%)	0.3005	+0.0110
625 (99%)	0.2920	+0.0025

Bảng 17: Ablation Study - Logistic Regression (10,000 samples)

Số Components	LR Accuracy	Delta so với Baseline
Baseline (32×32)	0.3365	-
10	0.3205	-0.0160
25	0.3570	+0.0205
50	0.3610	+0.0245
75	0.3790	+0.0425
100	0.3735	+0.0370
96 (90%)	0.3730	+0.0365
209 (95%)	0.3830	+0.0465
625 (99%)	0.3485	+0.0120

Phân tích Ablation Study:**1. k-NN:**

- Tốt nhất: 25 components (0.3390, +4.95%)
- Giảm chiều vừa phải (25-50) tốt hơn không giảm
- Quá nhiều components (100+) làm giảm accuracy do overfitting
- 25 components tốt hơn 96 (90% variance) vì loại bỏ noise

2. Logistic Regression:

- Tốt nhất: 209 components (0.3830, +4.65%)
- LR được PCA giảm chiều đáng kể (+4.65%)
- 209 components tốt nhất, tương ứng với 95% variance

3. So sánh:

- k-NN: Peak ở 25 components (+4.95%)
- LR: Peak ở 209 components (+4.65%)
- k-NN benefit nhiều hơn từ PCA (+4.95% vs +4.65%)

t-SNE vs PCA Visualization:

- t-SNE cho thấy rõ hơn cấu trúc cụm cục bộ
- PCA cho thấy phương sai toàn cục
- Cả hai đều có silhouette âm, xác nhận CIFAR-10 khó phân tách

Kết luận:

1. PCA giảm chiều hiệu quả: Giảm 79.7% features vẫn giữ 99% variance, cải thiện accuracy đáng kể
2. Số components tối ưu: k-NN: 25 (+4.95%); LR: 209 (+4.65%)
3. Silhouette Score âm: Các lớp chồng lấn nhiều, cần deep learning (CNN features)
4. **Điểm quan trọng:** Explained Variance $\neq$ Classification Accuracy (giữ nhiều variance không luôn tốt cho classification)

Hạn chế: Chỉ test với k-NN và LR, chưa test CNN.

Hướng cải tiến: Thử non-linear dimensionality reduction (t-SNE không dùng được cho classification), sử dụng autoencoder.

1.4.6 Phát hiện cạnh và ANOVA

Áp dụng các bộ phát hiện cạnh (Sobel, Prewitt, Canny) và kiểm định ANOVA để đánh giá khả năng phân biệt của edge features.

Bảng 18: Edge Density theo phương pháp và cấu hình

Cấu hình	Phương pháp	Parameters	Mean Edge Density
Sobel (ksize=3)	Sobel	ksize=3	0.9694
Sobel (ksize=5)	Sobel	ksize=5	0.9747
Prewitt	Prewitt	default	0.9708
Canny (50,150)	Canny	minVal=50, maxVal=150	0.2503
Canny (100,200)	Canny	minVal=100, maxVal=200	0.2168

Kết quả kiểm định ANOVA (Canny 50-150):

- F-statistic: 342.68
- p-value: ≈ 0
- Kết luận: Có sự khác biệt có ý nghĩa thống kê về edge density giữa các lớp

Phân tích:

- Sobel/Prewitt có edge density rất cao ($\sim 97\%$) vì detect tất cả edges
- Canny có edge density thấp hơn ($\sim 25\%$) vì chỉ giữ edges mạnh
- Deer và dog có edge density cao nhất (hình dạng phức tạp, nhiều chi tiết)
- Airplane có edge density thấp nhất (bề mặt tương đối đồng nhất)
- ANOVA $F=342.68$ cho thấy edge density CÓ khả năng phân biệt các lớp

Thảo luận: Edge density cho thấy khả năng phân biệt giữa các lớp trong CIFAR-10:

- ANOVA p-value $\approx 0 \rightarrow$ Có bằng chứng thống kê edge density khác nhau giữa các lớp
- Edge features có thể được sử dụng như một dạng feature bổ sung
- Tuy nhiên, simple classifiers (k-NN, LR) không benefits đáng kể từ edge features

Hạn chế: Edge detection tăng computational cost mà không cải thiện đáng kể simple classifiers.

Hướng cải tiến: Thử kết hợp edge features với color features, sử dụng CNN với edge-aware architectures.

1.5 Tổng kết lựa chọn cuối cùng

Bảng 19: Tổng kết các lựa chọn cuối cùng cho Phần 1

Kỹ thuật	Lựa chọn	Lý do
Resize	28×28	SSIM cao (0.9846), Acc +1.15%
Color Space	LAB	k-NN +1.25%, LR tốt nhất
Normalization	Min-Max [0,1]	LR +6.25%, phổ biến
Class Imbalance	Không cần xử lý (đã cân bằng)	IR = 1.10, p = 0.55
Duplicate	Không cần xử lý	Chỉ 1 cặp trùng

1.6 Hạn chế và hướng cải tiến

- **Hạn chế:**
 - Chỉ sử dụng data_batch_1 (10,000 ảnh), không đủ để generalize
 - Ablation study với k-NN/LR đơn giản, chưa test với CNN
 - LAB conversion cần thư viện OpenCV, không tương thích với tất cả frameworks

- **Hướng cải tiến:**

- Test với toàn bộ CIFAR-10 (50,000 ảnh)
- Sử dụng CNN (ResNet, VGG) để đánh giá ablation
- Thử các phương pháp augmentation nâng cao (CutMix, MixUp)
- Experiment với AutoAugment, RandAugment

2 Phần 2: Tiền xử lý dữ liệu dạng bảng

2.1 Mô tả tập dữ liệu

Tập dữ liệu: Adult Income Dataset (Census Income Dataset)

Mô tả: Tập dữ liệu dạng bảng với 15 thuộc tính gồm có:

- 6 thuộc tính số (numerical features): `fnlwgt`, `education-num`, `capital-gain`, `capital-loss`, `hour-per-week`
- 8 thuộc tính phân loại (categorical features): `workclass`, `education`, `occupation`, `marital-status`, `relationship`, `race`, `sex`, `native-country`
- 1 biến mục tiêu: `income` ($>50k$, $\leq 50k$)

Yêu cầu thường gặp là phân loại thu nhập của một người có vượt qua 50,000 USD/1 năm hay không dựa trên các đặc trưng đầu vào.

Kích thước: 48842 dòng với 14 đặc trưng và 1 đặc trưng mục tiêu.

Missing value: Tập dữ liệu có missing value trên thuộc tính `workclass` với 5.73%, `occupation` với 5.75% và `native-country` với 1.75%.

Nguồn: [UCI-AdultIncome](#)

2.2 Phân tích thống kê khám phá (EDA chuyên sâu)

Mục tiêu của phần EDA chuyên sâu là kiểm tra phân phối, phân tích tương quan đa biến và phân tích cơ chế thiếu dữ liệu để làm cơ sở chọn chiến lược tiền xử lý phù hợp. Toàn bộ phân tích đã được thực hiện trong notebook:

2.2.1 Kiểm tra phân phối từng thuộc tính số

Do mỗi biến số có $n = 32,561 > 5000$, kiểm định được sử dụng là **D'Agostino-Pearson**. Mức ý nghĩa: $\alpha = 0.05$.


Thuộc tính	Kiểm định	<i>p</i> -value	Phân loại	Chuẩn hóa đề xuất
age	D'Agostino-Pearson	0.000e+00	Không chuẩn	RobustScaler / QuantileTransformer

Thuộc tính	Kiểm định	p -value	Phân loại	Chuẩn hóa đề xuất
fnlwgt	D'Agostino-Pearson	0.000e+00	Không chuẩn	RobustScaler / QuantileTransformer
capital-gain	D'Agostino-Pearson	0.000e+00	Không chuẩn	RobustScaler / QuantileTransformer
capital-loss	D'Agostino-Pearson	0.000e+00	Không chuẩn	RobustScaler / QuantileTransformer
hours-per-week	D'Agostino-Pearson	0.000e+00	Không chuẩn	RobustScaler / QuantileTransformer
education-num	D'Agostino-Pearson	3.590e-178	Không chuẩn	RobustScaler / QuantileTransformer

Kết luận: Tất cả biến số đều có $p < 0.05$, do đó không tuân theo phân phối chuẩn. Vì vậy, ưu tiên chuẩn hóa bền vững với lệch phân phối/outlier (RobustScaler hoặc QuantileTransformer), thay vì StandardScaler thuần.

2.2.2 Phân tích tương quan đa biến (Pearson và Spearman)

Mã trận tương quan Pearson và Spearman được trực quan hóa bằng heatmap.



Hình 1: Mã trận tương quan Pearson và Spearman

- $\max |r_{\text{Pearson}}|$ (ngoài đường chéo): **0.1481**
- $\max |r_{\text{Spearman}}|$ (ngoài đường chéo): **0.1672**
- Số cặp có $|r| > 0.9$: **0**

Kết luận: Không phát hiện đa cộng tuyến mạnh theo ngưỡng thường dùng $|r| > 0.9$. Do đó chưa cần loại bỏ đặc trưng theo tiêu chí tương quan mạnh.

2.2.3 Phân tích giá trị thiếu và cơ chế thiếu dữ liệu

Trực quan missing data: Ma trận thiếu dữ liệu (missing data matrix) được vẽ bằng thư viện `missingno` trong notebook.

Tỷ lệ thiếu:

- `occupation`: 5.660%
- `workclass`: 5.639%
- `native-country`: 1.790%

Little's MCAR test:

- p -value từ Little's MCAR test: **0**
- Kết luận kiểm định: **Bác bỏ H_0 (dữ liệu không thiếu theo MCAR)**

Suy luận cơ chế thiếu (MCAR/MAR/MNAR) Trong notebook, trạng thái thiếu có liên hệ có ý nghĩa thống kê với nhiều biến quan sát được (ví dụ: `workclass-occupation`, `occupation-hours-per-week`, `native-country-race`, ...). Điều này phù hợp nhất với cơ chế **MAR** (Missing At Random), không phù hợp với MCAR.

Kết luận:

- Loại trừ MCAR bằng kiểm định Little.
- Cơ chế thiếu hợp lý nhất: **MAR**.
- Hướng xử lý khuyến nghị: bù thiếu dựa trên thông tin biến quan sát (group-wise imputation, MICE/Iterative Imputer, mô hình hóa missingness indicator).

Tổng hợp quyết định cho bước tiền xử lý

- **Chuẩn hóa biến số:** dùng `RobustScaler` hoặc `QuantileTransformer`.
- **Đa cộng tuyến:** chưa cần xử lý loại biến theo ngưỡng tương quan mạnh.
- **Giá trị thiếu:** xử lý theo giả định MAR, tránh xóa dòng hàng loạt.

2.3 Tóm tắt điều hành

Báo cáo này trình bày một quy trình tiền xử lý dữ liệu bằng toàn diện trên tập dữ liệu **Adult Census Income**, bao gồm phân tích thống kê khám phá chuyên sâu, xử lý giá trị thiếu, phát hiện ngoại lai, chuẩn hóa, mã hóa biến phân loại, lựa chọn và giảm chiều đặc trưng và xử lý mất cân bằng lớp. Mục tiêu là xây dựng một pipeline tối ưu, sẵn sàng cho các mô hình học máy, với trọng tâm là đánh giá định lượng và so sánh các kỹ thuật khác nhau.

Các phát hiện chính:

1. **Xử lý giá trị thiếu:** Phương pháp **Mean Imputation** cho kết quả tương đương **MICE** ($p > 0.05$ chứng tỏ không có ý nghĩa thống kê về sự khác biệt giữa hai phương pháp) nhưng nhanh hơn đáng kể, do đó được chọn cho các biến số. Đối với biến phân loại, **Mode Imputation** vượt trội so với gán hằng số.

2. **Phát hiện ngoại lai: Isolation Forest (contamination = 0.05)** được chọn nhờ tỉ lệ phát hiện hợp lý (5%), độ chồng lấn (Jaccard similarity) tốt với DBSCAN và tác động có ý nghĩa thống kê đến phân phối biến ($p < 0.05$), thể hiện khả năng phát hiện ngoại lai đa chiều hiệu quả.
3. **Chuẩn hóa: Z-score (StandardScaler)** được khuyến nghị cho hầu hết các mô hình học máy nhờ khả năng chuẩn hóa scale mà vẫn giữ hình dạng phân phối gốc. **Quantile Normal** là lựa chọn tối ưu khi yêu cầu dữ liệu có phân phối chuẩn hoặc đồng nhất phương sai.
4. **Mã hóa biến phân loại: Target Encoding với Cross-Validation (K-Fold)** được chứng minh là vượt trội, đặc biệt cho các biến có nhiều giá trị (high-cardinality) như `occupation` và `native-country`. Phương pháp này vừa giữ được chỉ số VIF (Variance Inflation Factor) rất thấp (≈ 1.0), vừa tránh được hiện tượng rò rỉ dữ liệu (data leakage).
5. **Lựa chọn và giảm chiều đặc trưng:** Các phương pháp dựa trên mô hình như **Gradient Boosting Importance** và **RFECV** (Recursive Feature Elimination with Cross-Validation) cho hiệu suất F1 tốt nhất ($F1 \approx 0.636$) với số lượng đặc trưng được chọn lọc (khoảng 40–80). PCA cho thấy có thể giảm chiều mà không làm giảm hiệu năng đáng kể. t-SNE và UMAP là công cụ trực quan hóa hữu ích.
6. **Xử lý mất cân bằng lớp: Random Under-sampling** và **SMOTE** (Synthetic Minority Over-sampling Technique) đều cải thiện đáng kể **recall** của lớp thiểu số ($>50K$) so với baseline, với F1-macro tương đương (≈ 0.754). Random Under-sampling được đánh giá cao hơn một chút về F1-macro và AUC-ROC trong thử nghiệm này.


Kết luận: Pipeline tiền xử lý đề xuất kết hợp **Mean Imputation**, **Isolation Forest**, **Z-score Normalization**, **Target Encoding** (cho biến high-cardinality) và **One-Hot Encoding** (cho biến low-cardinality). Đối với bài toán phân loại mất cân bằng, nên áp dụng **Random Under-sampling** hoặc **SMOTE** trên tập huấn luyện sau khi đã tách train/test.

2.4 Các kỹ thuật tiền xử lý và đánh giá định lượng

2.4.1 Xử lý giá trị thiếu

Bảng 21: So sánh các phương pháp điền khuyết trên biến số (dựa trên RMSE trung bình sau 10 lần lặp)

Phương pháp	Mean RMSE	Std RMSE	Ghi chú
MICE	43149.60	610.56	Phức tạp, chậm nhất
Mean	43151.03	610.95	Được chọn (nhANH, hiệu quả tương đương MICE)
Median	43389.44	624.19	Bền vững với outlier
Mode	45926.06	3897.71	Không ổn định, RMSE cao
kNN (k=10)	45250.24	521.06	Tốt nhất trong nhóm kNN, độ phức tạp thời gian lớn
kNN (k=5)	47490.73	693.96	Độ phức tạp thời gian lớn
kNN (k=3)	49236.10	1549.91	Độ phức tạp thời gian lớn



Hình 2: Minh họa so sánh các phương pháp điền khuyết

Thảo luận: Kết quả từ Bảng 21 và Hình 2 cho thấy **Mean Imputation** và **MICE** có hiệu suất gần như tương đương (paired t-test $p = 0.1125 > 0.05$, không có sự khác biệt thống kê). Mặc dù MICE có thể mô hình hóa mối quan hệ đa biến phức tạp, nhưng chi phí tính toán rất lớn. Do đó, nhóm chọn **Mean Imputation** để ưu tiên tốc độ mà không làm giảm độ chính xác đáng kể.

Đối với biến phân loại, **Mode Imputation** (thay bằng giá trị xuất hiện nhiều nhất) vượt trội hoàn toàn so với gán hằng số 'Unknown' (accuracy 59.6% so với 0%).

Hạn chế: Mean Imputation làm giảm phương sai dữ liệu và nhạy cảm với outlier.

Hướng cải tiến: Có thể thử nghiệm **IterativeImputer** với các vòng lặp và mô hình hồi quy khác nhau để cải thiện độ chính xác nếu tài nguyên cho phép.

2.4.2 Phát hiện và xử lý ngoại lai

Bảng 22: So sánh các phương pháp phát hiện ngoại lai

Phương pháp	Tỉ lệ ngoại lai	Jaccard (so với IF)	KS-test p-value (age)
IQR + Z-score	41.53%	0.120	0.000000
Isolation Forest (0.05)	5.00%	1.000	0.001824
LOF (n=20)	4.15%	0.049	0.999993
DBSCAN (eps=0.5)	7.01%	0.426	0.000013

Thảo luận: **Isolation Forest** được chọn vì tỉ lệ phát hiện hợp lý (5%), độ tương tự (Jaccard) khá cao với DBSCAN (0.426) cho thấy sự nhất quán trong việc phát hiện ngoại lai đa chiều. Kiểm định Kolmogorov-Smirnov (KS-test) cho thấy việc loại bỏ ngoại lai bằng Isolation Forest làm thay đổi phân phối của biến **age** một cách có ý nghĩa ($p < 0.05$), chứng tỏ nó thực sự xác định được các điểm bất thường. LOF có độ tương tự rất thấp với các phương pháp khác và hầu như không ảnh hưởng đến phân phối **age** (p gần bằng 1), có thể đang bỏ sót ngoại lai. IQR+Z-score phát hiện quá nhiều điểm (41.5%), không thực tế.

Hạn chế: **contamination** là tham số ước lượng, có thể cần điều chỉnh cho từng bộ dữ liệu.

Hướng cải tiến: Có thể sử dụng phương pháp **GridSearchCV** để tối ưu tham số **contamination** dựa trên một số chỉ số như Silhouette score.

2.4.3 Chuẩn hóa dữ liệu

Bảng 23: So sánh các phương pháp chuẩn hóa

Phương pháp	Đặc điểm chính	Levene p-value	Ứng dụng đề xuất
Min-Max	Co dữ liệu về $[0, 1]$, giữ hình dạng	0.0	Khi cần dữ liệu trong khoảng nhất định (ví dụ: Neural Networks)
Z-score	Trung bình 0, độ lệch chuẩn 1, giữ hình dạng	0.0	Mặc định cho nhiều mô hình (Hồi quy, SVM, KNN)
Robust Scaler	Sử dụng trung vị và IQR, ít ảnh hưởng bởi outlier	0.0	Khi dữ liệu có nhiều outlier
Quantile Uniform	Biến đổi về phân phối đều $[0, 1]$	0.0	Cần đồng nhất phân phối giữa các đặc trưng
Quantile Normal	Biến đổi về phân phối chuẩn	0.0	Cần dữ liệu có phân phối chuẩn hoặc phương sai đồng nhất

Thảo luận: Mặc dù kiểm định Levene cho thấy sự khác biệt phương sai vẫn tồn tại ($p \approx 0$) ở tất cả các phương pháp do cỡ mẫu lớn, trực quan hóa bằng **violin plot** cho thấy **Z-score** và **Robust Scaler** vẫn giữ được hình dạng phân phối đặc trưng của từng biến, trong khi **Quantile Transform** làm cho các biến có cùng hình dạng (uniform hoặc normal). **Z-score** được chọn vì sự cân bằng tốt giữa việc chuẩn hóa scale và bảo toàn cấu trúc dữ liệu, phù hợp với đa số thuật toán học máy.

Hạn chế: Z-score rất nhạy cảm với outlier.

Hướng cải tiến: Nên sử dụng **RobustScaler** nếu phát hiện outlier trong giai đoạn tiền xử lý trước đó chưa loại bỏ hoàn toàn.

2.4.4 Mã hóa biến phân loại

Bảng 24: So sánh các phương pháp mã hóa (trên biến *occupation*)

Phương pháp	Số chiều sau mã hóa	VIF (trung bình)	Ưu điểm chính
One-Hot Encoding	14	~ 1.28	Đơn giản, không giả định thứ tự
Binary Encoding	4	~ 1.27	Giảm chiều tốt hơn One-Hot
Frequency Encoding	1	1.0	Rất đơn giản, VIF thấp
Target Encoding (CV)	1	1.0	Mã hóa dựa trên thông tin target, VIF thấp, tránh leakage

Thảo luận: **Target Encoding với Cross-Validation** là lựa chọn tối ưu. Nó không chỉ giữ VIF ở mức lý tưởng (1.0) mà còn chuyển đổi các nhãn định tính thành xác suất đóng góp vào biến mục tiêu (`income_bin`), giúp tăng sức mạnh dự báo cho mô hình. Phân tích VIF toàn cục (Global VIF) sau khi áp dụng các phương pháp mã hóa cho thấy tất cả các biến đều có $VIF < 1.5$, khẳng định không có hiện tượng đa cộng tuyến nghiêm trọng.

Hạn chế: Target Encoding có thể gây overfitting nếu không được thực hiện cẩn thận với cross-validation.

Hướng cải tiến: Có thể thêm một lượng smoothing (trọng số giữa trung bình nhóm và trung bình toàn cục) để tăng độ ổn định cho các nhóm có ít mẫu.

2.4.5 Lựa chọn và giảm chiều đặc trưng

Bảng 25: Hiệu suất (F1-Macro) của các phương pháp chọn đặc trưng tốt nhất

Phương pháp	Số đặc trưng tốt nhất	F1-Macro (CV)
Gradient Boosting Importance	40	0.6364
RF_importance	80	0.6351
RFECV	84	0.6351
ANOVA F-test	104	0.6346
Chi-square	104	0.6346
Mutual Information (MI)	80	0.6339

Thảo luận: Các phương pháp dựa trên mô hình (model-based) như **Gradient Boosting (GB)** và **Random Forest (RF)** cho hiệu suất F1 cao nhất với số lượng đặc trưng được chọn lọc ít hơn so với các phương pháp thống kê (ANOVA, Chi-square). **RFECV** tự động tìm được số lượng đặc trưng tối ưu (84) với $F1 \approx 0.635$. PCA cho thấy có thể giảm chiều dữ liệu xuống còn khoảng 60 thành phần mà không làm giảm F1 đáng kể, hữu ích cho việc giảm tải tính toán. t-SNE và UMAP là các công cụ trực quan hóa mạnh mẽ, giúp khám phá cấu trúc cụm của dữ liệu.

Hạn chế: Các phương pháp model-based phụ thuộc vào mô hình ước lượng importance (ví dụ: GB, RF).

Hướng cải tiến: Có thể kết hợp kết quả chọn đặc trưng từ nhiều phương pháp khác nhau (ensemble feature selection) để tăng độ tin cậy.

2.4.6 Phát hiện và xử lý mất cân bằng lớp

Bảng 26: Đánh giá các chiến lược cân bằng lớp trên tập kiểm tra (test set)

Chiến lược	Precision (macro)	Recall (macro)	F1-macro	AUC-ROC
Baseline (Không xử lý)	0.7943	0.7411	0.7619	0.8973
Random Under-sampling	0.7383	0.8181	0.7548	0.8971
SMOTE	0.7367	0.8138	0.7536	0.8952
ADASYN	0.7205	0.8074	0.7285	0.8916

Thảo luận: Mất cân bằng lớp là một thách thức rõ rệt (tỷ lệ lớp $\leq 50K$ chiếm $\approx 78\%$ so với $>50K \approx 22\%$). Các kỹ thuật tái cân bằng (resampling) đã cải thiện đáng kể **recall** của

lớp thiểu số (từ 0.741 lên 0.81), thể hiện khả năng dự đoán đúng các mẫu có thu nhập cao tốt hơn. **Random Under-sampling** cho kết quả F1-macro và AUC-ROC cao nhất trong thử nghiệm này, có thể do việc loại bỏ bớt mẫu đa số giúp mô hình tập trung vào ranh giới quyết định hơn. SMOTE và ADASYN cũng cho kết quả khả quan.

Hạn chế: Under-sampling có thể loại bỏ các mẫu quan trọng của lớp đa số.

Hướng cải tiến: Có thể kết hợp Under-sampling và Over-sampling (phương pháp lai ghép) hoặc sử dụng các thuật toán tự xử lý imbalance như BalancedRandomForest hoặc XGBoost với tham số `scale_pos_weight`.

2.5 Kết luận chung

Quy trình tiền xử lý đề xuất đã được xây dựng và đánh giá một cách có hệ thống. Các lựa chọn cuối cùng được đưa ra dựa trên bằng chứng định lượng rõ ràng, đảm bảo tính hiệu quả và khả năng tổng quát hóa cho các bước xây dựng mô hình tiếp theo. Các hạn chế và hướng cải tiến cũng đã được chỉ ra, tạo cơ sở để phát triển pipeline trong tương lai.

3 Phần 3: Tiền xử lý dữ liệu chuỗi thời gian

3.1 Mô tả tập dữ liệu

Tập dữ liệu: Dữ liệu lịch sử giá cổ phiếu mã VNDA.

Đặc điểm: Đây là tập dữ liệu dạng chuỗi thời gian (Time-series data), ghi nhận biến động giá cổ phiếu theo từng ngày giao dịch trên thị trường chứng khoán.

Khoảng thời gian: Từ năm 2006 đến năm 2022.

Mô tả chi tiết: Tập dữ liệu gồm 4197 quan sát (dòng), với các thuộc tính chính như sau:

- **Date:** Biến thời gian, thể hiện ngày giao dịch (định dạng datetime).
- **Open:** Giá mở cửa của cổ phiếu trong phiên giao dịch.
- **High:** Giá cao nhất đạt được trong phiên giao dịch.
- **Low:** Giá thấp nhất trong phiên giao dịch.
- **Close:** Giá đóng cửa của cổ phiếu.
- **Adjusted Close:** Giá đóng cửa đã được điều chỉnh (đã tính đến chia tách cổ phiếu, cổ tức).
- **Volume:** Khối lượng cổ phiếu được giao dịch trong ngày.

Biến mục tiêu: Biến **Adjusted Close** được sử dụng làm biến mục tiêu để phục vụ cho các bài toán dự báo giá cổ phiếu.

Kích thước dữ liệu: 4197 dòng và 7 thuộc tính (bao gồm cả biến thời gian).

Giá trị thiếu (Missing values): Qua kiểm tra ban đầu, tập dữ liệu không chứa giá trị thiếu đáng kể. Trong trường hợp tồn tại các khoảng trống do ngày nghỉ giao dịch (cuối tuần, ngày lễ), dữ liệu sẽ được xử lý ở các bước nội suy phía sau.

Nguồn dữ liệu: [Stock Market Data \(NASDAQ, NYSE, S&P500\)](#)

3.2 Nhận xét ban đầu

Từ việc quan sát và phân tích sơ bộ tập dữ liệu, có thể rút ra một số nhận xét quan trọng:

- Dữ liệu có tính **phụ thuộc theo thời gian** (temporal dependency), tức là giá trị tại thời điểm hiện tại chịu ảnh hưởng từ các thời điểm trước đó.
- Các biến giá (Open, High, Low, Close, Adjusted Close) có xu hướng tương quan mạnh với nhau.
- Chuỗi giá cổ phiếu thường **không dừng (non-stationary)**, thể hiện qua xu hướng tăng/giảm theo thời gian.
- Dữ liệu có thể chứa **hiều và biến động mạnh**, đặc biệt trong các giai đoạn thị trường biến động.
- Không tồn tại dữ liệu thiếu rõ ràng, tuy nhiên có thể tồn tại các khoảng thời gian không giao dịch cần xử lý.

Những đặc điểm trên cho thấy cần áp dụng các kỹ thuật tiền xử lý chuyên biệt cho dữ liệu chuỗi thời gian như kiểm định tính dừng, phân rã chuỗi và trích xuất đặc trưng theo thời gian.

3.3 Tóm tắt điều hành

Phần này thực hiện tiền xử lý dữ liệu chuỗi thời gian giá cổ phiếu VNDA giai đoạn 2006–2022 nhằm phục vụ bài toán dự báo.

Các phát hiện chính:

1. Chuỗi dữ liệu ban đầu **không dừng**, với ADF p-value = 0.0653 (>0.05) và KPSS p-value = 0.0100 (<0.05).
2. Các phép biến đổi log và Box-Cox không giúp chuỗi đạt tính dừng.
3. Sau khi áp dụng **sai phân bậc 1**, chuỗi trở nên dừng với ADF p-value = 0.0000 và KPSS p-value = 0.1000.
4. Phương pháp **Linear Interpolation** cho kết quả tốt nhất trong xử lý dữ liệu thiếu với RMSE = 0.5631.
5. STL decomposition cho thấy **trend rõ ràng** và **seasonality yếu**, residual variance chỉ chiếm 1.46% so với dữ liệu gốc.

6. Feature engineering giúp trích xuất được các đặc trưng quan trọng như rolling mean và cyclic encoding.

Khuyến nghị: Sử dụng pipeline gồm differencing + linear interpolation + feature engineering.

3.4 Phân tích khám phá dữ liệu (EDA)

3.4.1 Biểu đồ chuỗi thời gian

Biểu đồ chuỗi thời gian của giá cổ phiếu VNDA trong giai đoạn 2006–2022 cho thấy:

- Chuỗi có **xu hướng dài hạn rõ ràng**, thể hiện sự tăng/giảm theo từng giai đoạn thị trường
- Xuất hiện các **biến động mạnh** tại một số thời điểm, phản ánh ảnh hưởng của các yếu tố kinh tế
- Không quan sát thấy chu kỳ lặp lại rõ ràng theo mùa

Nhận xét: Chuỗi có dấu hiệu **không dừng** do mean thay đổi theo thời gian.

3.4.2 Phân tích Rolling Statistics

Để kiểm tra tính dừng của chuỗi, rolling mean và rolling standard deviation được tính với cửa sổ 30 ngày.


- Rolling mean thay đổi đáng kể theo thời gian
- Rolling standard deviation không ổn định

Kết luận: Mean và variance không cố định → chuỗi **không dừng**.

3.4.3 Phân tích ACF và PACF


Phân tích hàm tự tương quan (ACF) và tự tương quan riêng phần (PACF):

- ACF giảm chậm theo độ trễ → chuỗi có xu hướng (trend)
- PACF có spike rõ ràng tại lag 1



Hình 3: Biểu đồ ACF của chuỗi giá cổ phiếu VNDA

Có thể quan sát thấy hệ số tự tương quan giảm chậm theo các độ trễ (lag), cho thấy chuỗi có xu hướng (trend) và **không dừng**. Điều này gợi ý cần thực hiện sai phân để loại bỏ xu hướng trước khi xây dựng mô hình.



Hình 4: Biểu đồ PACF của chuỗi giá cổ phiếu VNDA

Spike rõ ràng tại lag 1 cho thấy giá trị hiện tại phụ thuộc mạnh vào giá trị trước đó. Sau lag 1, các hệ số giảm nhanh về gần 0, gợi ý rằng mô hình AR(1) có thể phù hợp.

Nhận xét tổng hợp:

- ACF giảm chậm $\rightarrow$ chuỗi có xu hướng và không dừng
- PACF có spike tại lag 1 $\rightarrow$ gợi ý thành phần AR(1)

Kết luận: Cần thực hiện sai phân bậc 1 để đưa chuỗi về trạng thái dừng trước khi xây dựng mô hình.

3.4.4 Phân phối dữ liệu

Phân phối của biến giá đóng cửa (Adjusted Close) có các đặc điểm:

- Phân phối lệch phải (right-skewed)
- Xuất hiện một số giá trị ngoại lai (outliers)

Nhận xét:

- Dữ liệu không tuân theo phân phối chuẩn
- Có thể cần xử lý outliers hoặc biến đổi log

3.4.5 Tổng kết EDA

Từ các phân tích trên, có thể rút ra các kết luận chính:

- Chuỗi dữ liệu **không dừng** (non-stationary)
- Có **xu hướng dài hạn** rõ ràng
- Không có seasonality rõ ràng

- Phân phối dữ liệu lệch và có outliers

Hàm ý tiền xử lý:

- Cần áp dụng sai phân (differencing)
- Có thể sử dụng log transform
- Cần kiểm tra và xử lý outliers

3.5 Các kỹ thuật tiền xử lý

3.5.1 Xử lý dữ liệu thiếu

Trong tập dữ liệu chuỗi thời gian giá cổ phiếu VNDA, một số thời điểm xuất hiện giá trị bị thiếu do gián đoạn giao dịch hoặc lỗi thu thập dữ liệu. Việc xử lý dữ liệu thiếu là cần thiết nhằm đảm bảo tính liên tục của chuỗi thời gian và tránh ảnh hưởng đến các bước phân tích tiếp theo.

Các phương pháp nội suy (interpolation) được thử nghiệm bao gồm:

- Forward Fill (điền giá trị trước đó)
- Linear Interpolation
- Polynomial Interpolation (bậc 2, bậc 3)
- Spline Interpolation (cubic)

Bảng 27: So sánh các phương pháp xử lý dữ liệu thiếu

Phương pháp	MAE	RMSE
Forward Fill	0.3387	0.8644
Linear Interpolation	0.2501	0.5631
Polynomial (order=2)	0.3015	0.6931
Polynomial (order=3)	0.3041	0.6878
Spline (cubic)	0.8262	1.1695

Phân tích:

- Linear Interpolation cho kết quả tốt nhất với $MAE = 0.2501$ và $RMSE = 0.5631$, cho thấy khả năng ước lượng giá trị thiếu chính xác và ổn định.
- Forward Fill có sai số lớn hơn do chỉ sử dụng thông tin từ giá trị trước đó, không phản ánh được xu hướng biến động.
- Polynomial Interpolation cải thiện so với Forward Fill nhưng vẫn kém hơn Linear do dễ bị ảnh hưởng bởi nhiễu.
- Spline Interpolation cho kết quả kém nhất ($RMSE = 1.1695$), có thể do hiện tượng overfitting khi nội suy trên dữ liệu tài chính có biến động mạnh.

Kết luận:

Linear Interpolation được lựa chọn làm phương pháp xử lý dữ liệu thiếu cho bài toán, do đạt sai số thấp nhất và phù hợp với đặc điểm biến động liên tục của dữ liệu chuỗi thời gian tài chính.

3.5.2 Kiểm định tính dừng

Tính dừng (stationarity) là một giả định quan trọng trong phân tích chuỗi thời gian, đặc biệt đối với các mô hình như ARIMA. Một chuỗi được coi là dừng khi các đặc trưng thống kê như kỳ vọng và phương sai không thay đổi theo thời gian.

Để kiểm tra tính dừng của chuỗi giá cổ phiếu VNDA, hai kiểm định phổ biến được sử dụng:

- **ADF (Augmented Dickey-Fuller):** giả thuyết H_0 là chuỗi *không dừng*
- **KPSS (Kwiatkowski-Phillips-Schmidt-Shin):** giả thuyết H_0 là chuỗi *dừng*

Bảng 28: Kết quả kiểm định tính dừng

Phương pháp	ADF p-value	KPSS p-value
Chuỗi gốc	0.0653	0.0100
Log Transform	0.1012	0.0100
Box-Cox Transform	0.0739	0.0100

Phân tích:

- Với chuỗi gốc, ADF p-value = 0.0653 (> 0.05) $\rightarrow$ không bác bỏ H_0 , cho thấy chuỗi **không dừng**.
- KPSS p-value = 0.0100 (< 0.05) $\rightarrow$ bác bỏ H_0 , xác nhận chuỗi **không dừng**.
- Các phép biến đổi Log và Box-Cox không cải thiện tính dừng, do vẫn cho kết quả p-value không đạt ngưỡng yêu cầu.

Kết luận:

Chuỗi dữ liệu ban đầu là **không dừng**, và các phép biến đổi tuyến tính như Log hoặc Box-Cox không đủ để loại bỏ xu hướng. Do đó, cần áp dụng các phương pháp mạnh hơn như sai phân (differencing).

3.5.3 Biến đổi dữ liệu

Để đưa chuỗi về trạng thái dừng, phương pháp sai phân bậc 1 được áp dụng. Phương pháp này loại bỏ xu hướng bằng cách lấy hiệu giữa các giá trị liên tiếp trong chuỗi.

Bảng 29: Kết quả kiểm định sau sai phân

Phương pháp	ADF p-value	KPSS p-value
Sai phân bậc 1	0.0000	0.1000

Phân tích:

- ADF p-value = 0.0000 (< 0.05) $\rightarrow$ bác bỏ H_0 , cho thấy chuỗi đã **dừng**.
- KPSS p-value = 0.1000 (> 0.05) $\rightarrow$ không bác bỏ H_0 , xác nhận chuỗi **dừng**.

- Hai kiểm định cho kết quả nhất quán, khẳng định hiệu quả của phương pháp sai phân.

Kết luận:

Sai phân bậc 1 là phương pháp hiệu quả nhất để đưa chuỗi về trạng thái dừng. Chuỗi sau khi biến đổi sẽ được sử dụng cho các bước phân tích và xây dựng mô hình tiếp theo.

3.5.4 Phân rã chuỗi thời gian

Để hiểu rõ cấu trúc của chuỗi thời gian, phương pháp phân rã STL (Seasonal-Trend decomposition using Loess) được áp dụng nhằm tách chuỗi thành ba thành phần chính:

- **Trend:** xu hướng dài hạn của dữ liệu
- **Seasonal:** yếu tố mùa vụ lặp lại theo chu kỳ
- **Residual:** nhiễu ngẫu nhiên

Bảng 30: Tỷ lệ phương sai của các thành phần sau phân rã

Thành phần	Variance Ratio
Trend	0.9132
Seasonal	0.0058
Residual	0.0810

Phân tích:

- Thành phần **Trend chiếm ưu thế** với 91.32% phương sai, cho thấy dữ liệu có xu hướng dài hạn rất rõ ràng.
- Thành phần **Seasonal rất nhỏ** (0.58%), chứng tỏ dữ liệu gần như không có tính mùa vụ rõ rệt.
- Thành phần **Residual** chiếm 8.10%, phản ánh mức độ nhiễu trong dữ liệu ở mức trung bình.

Kết luận:

Chuỗi thời gian chủ yếu bị chi phối bởi xu hướng (trend) và không có yếu tố mùa vụ đáng kể. Do đó, việc sử dụng sai phân là phù hợp để loại bỏ xu hướng, trong khi không cần thiết phải xử lý yếu tố mùa vụ trong mô hình.

3.5.5 Trích xuất đặc trưng

Để cải thiện khả năng học của mô hình, các đặc trưng bổ sung được trích xuất từ chuỗi thời gian nhằm cung cấp thêm thông tin về xu hướng và biến động.

Các nhóm đặc trưng được sử dụng bao gồm:

- **Lag Features:** các giá trị trễ của chuỗi (lag 1, lag 2, lag 3)

- **Rolling Statistics:** trung bình trượt (rolling mean) và độ lệch chuẩn trượt (rolling std)
- **Cyclic Features:** đặc trưng chu kỳ thời gian (ngày, tháng)
- **Statistical Features:** skewness và kurtosis

Bảng 31: So sánh hiệu quả của các đặc trưng

Loại đặc trưng	MAE	RMSE
Lag Features	0.4125	0.8932
Rolling Mean (window=7)	0.2981	0.6124
Cyclic Features	0.3054	0.6402
Statistical (Skew/Kurtosis)	0.3217	0.6725

Phân tích:

- **Rolling Mean** cho kết quả tốt nhất ($RMSE = 0.6124$), cho thấy khả năng làm mượt dữ liệu và nắm bắt xu hướng ngắn hạn hiệu quả.
- **Lag Features** có hiệu quả thấp hơn do chỉ sử dụng thông tin quá khứ đơn giản, chưa đủ để mô hình hóa xu hướng phức tạp.
- **Cyclic Features** không mang lại cải thiện đáng kể, phù hợp với kết quả ở phần phân rã cho thấy dữ liệu không có tính mùa vụ rõ rệt.
- **Statistical Features** (skewness, kurtosis) cung cấp thêm thông tin về phân phối nhưng không cải thiện nhiều hiệu suất mô hình.

Kết luận:

Rolling Mean là đặc trưng hiệu quả nhất trong bài toán này và được lựa chọn sử dụng trong pipeline cuối cùng. Các đặc trưng khác có thể được giữ lại để bổ sung nhưng không đóng vai trò quyết định.

3.6 Ablation Study**3.7 Thảo luận****3.8 Tổng kết**

4 Phân công công việc

Thành viên	Nhiệm vụ chi tiết	Đóng góp
Cao Tiến Thành	Chọn tập dữ liệu, thực hiện EDA dữ liệu bảng: kiểm tra phân phối, phân tích tương quan đa biến, phân tích giá trị thiếu, lựa chọn và giảm chiều đặc trưng, phát hiện và xử lý mất cân bằng lớp, viết báo cáo	20%
Đỗ Quốc Thịnh	Tiền xử lý dữ liệu bảng: xử lý giá trị thiếu có kiểm soát với 5 chiến lược, phát hiện và xử lý ngoại lai, chuẩn hóa dữ liệu có kiểm định, mã hóa biến phân loại nâng cao, viết báo cáo, kiểm tra chất lượng mã nguồn, nộp bài	20%
Cao Thanh Bình	Chọn data mẫu, vẽ time plot và xác định các thành phần, tính rolling statistic, kiểm định tính dừng của dữ liệu, trích xuất đặc trưng thời gian, xây dựng ma trận đặc trưng dự báo, viết báo cáo	20%
Nguyễn Văn Chiến	Xác định lag tối đa vẽ AFC, PACF, xử lý khoảng trống dữ liệu, tạo nhân tạo khoảng trống, phân ra chuỗi thời gian, áp dụng các phương pháp để phát hiện dị thường trên dữ liệu, viết báo cáo	20%
Đặng Nguyễn Thái Đạt	Thực hiện EDA toàn diện trên dữ liệu ảnh, thay đổi kích thước và chất lượng ảnh, chuyển đổi không gian màu, chuẩn hóa, tăng cường dữ liệu, phân tích PCA, phát hiện cạnh và phân tích đặc trưng cục bộ, viết báo cáo	20%

Bảng 32: Bảng phân công công việc nhóm

Thảo luận về sự phối hợp

Các thành viên tham gia thảo luận chung thông qua 2 hình thức: trực tuyến qua kênh Zalo của nhóm và trực tiếp sau giờ học trên lớp để thống nhất pipeline tiền xử lý cũng như thảo luận các vấn đề phát sinh về các kỹ thuật xử lý của mỗi phần.

Các thành viên thực hiện kiểm tra chéo mã nguồn và kết quả của nhau nhằm đảm bảo tính chính xác thống kê.

Mã nguồn của đồ án

Các thành viên đều sử dụng Git để quản lý các phiên bản mã nguồn. Repository đặt ở chế độ public. Để xem thêm thông tin chi tiết, xin vui lòng nhấn vào đường link sau đây:

<https://github.com/QUOCTHINH05/datamining-project1-preprocessing.git>

5 Tài liệu tham khảo

Phần 1: Tiền xử lý dữ liệu ảnh số

1. Krizhevsky, A., and Hinton, G. (2009). Learning Multiple Layers of Features from Tiny Images. Technical Report, University of Toronto.
2. Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612.
3. Bradski, G. (2000). The OpenCV Library. *Dr. Dobb's Journal of Software Tools*.
4. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
5. scikit-learn developers (2026). Retrieved from <https://scikit-learn.org>
6. pHash.org (2026). Retrieved from <https://phash.org>

Phần 2: Tiền xử lý dữ liệu bảng

- [1] J. Han, J. Pei, and H. Tong, "Data, measurements, and data preprocessing," in *Data Mining: Concepts and Techniques*, 4th ed. Cambridge, MA, USA: Elsevier, 2023, ch. 2, pp. 23–83.
- [2] Breunig, M. M., Kriegel, H. P., Ng, R. T., & Sander, J. (2000). LOF: identifying density-based local outliers. *ACM SIGMOD Record*.
- [3] Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *KDD*.
- [4] Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation forest. *ICDM*.